Eksperymenty z ważonym głosowaniem i marginesami

Complex Layers na zbiorze colon cancer

Jerzy Krawczuk

27 września 2026

Streszczenie

Raport podsumowuje dodatkowe eksperymenty wykonane po wysłaniu artykułu do recenzji. Nie stanowią one zmiany wysłanej wersji artykułu. Porównano cztery sposoby agregacji głosów kolejnych neuronów oraz przeanalizowano szerokość formalnego pasa, empiryczny signed geometric margin i czas trenowania. Eksperyment przeprowadzono na zbiorze colon cancer za pomocą 10-krotnej walidacji krzyżowej powtórzonej 10 razy, osobno dla modeli CPL, SVM i regresji logistycznej w reżimach low- i high-feature.

1 Konfiguracja eksperymentu

Zbiór colon cancer zawiera 62 obiekty, 2000 cech ekspresji genów i dwie klasy diagnostyczne. Dla każdej konfiguracji zastosowano repeated stratified cross-validation: 10 foldów i 10 powtórzeń, łącznie 100 splitów. Standaryzację dopasowywano wyłącznie na części treningowej każdego splitu. Kolejny neuron otrzymywał pulę cech pomniejszoną o cechy wybrane przez neurony wcześniejsze.

Użyto tych samych parametrów regularyzacji co w eksperymentach artykułu:

Model	C_{low}	C_{high}
CPL	2.0	8.0
SVM	1.3	5.2
Logistic regression	3.4	5.2

Wszystkie modele stosują regularyzację L1. Różnią się funkcją straty: CPL używa hinge loss rozwiązywanego jako program liniowy, SVM używa squared hinge loss, a regresja logistyczna—logistic loss. Norma L2 nie jest karą optymalizacyjną; służy wyłącznie do późniejszego pomiaru geometrii wytrenowanego neuronu.

2 Cztery sposoby głosowania

Niech wynik liniowy neuronu i będzie równy

$$f_i(x) = w_i^\top x + b_i.$$

Porównano następujące strategie:

1. **Uniform voting**: każdy neuron oddaje głos o tej samej wadze.

2. **Training-BA voting**: stała waga neuronu jest wyznaczana wyłącznie z jego balanced accuracy na foldzie treningowym:

$$q_i = \max(0, \mathrm{BA}_i^{\mathrm{train}} - 0.5), \qquad \alpha_i = \frac{q_i}{\sum_j q_j}.$$

   Jeżeli wszystkie q_i są równe zero, stosowane są wagi jednakowe.

3. **Inverse-L2-norm voting**: propozycja oparta na formalnej szerokości pasa. Stała waga neuronu jest proporcjonalna do

$$\alpha_i \propto \frac{1}{\|w_i\|_2}.$$

4. **Sample-distance voting**: waga zależy od klasyfikowanego obiektu. Siła głosu wynosi

$$D_i(x) = \frac{|f_i(x)|}{\|w_i\|_2},$$

   a końcowa decyzja jest równoważna znakowi sumy

$$\sum_i \frac{f_i(x)}{\|w_i\|_2}.$$

Wszystkie strategie są obliczane z tych samych dopasowanych neuronów. Zmiana sposobu głosowania nie wymaga ponownego treningu i nie korzysta z etykiet testowych.

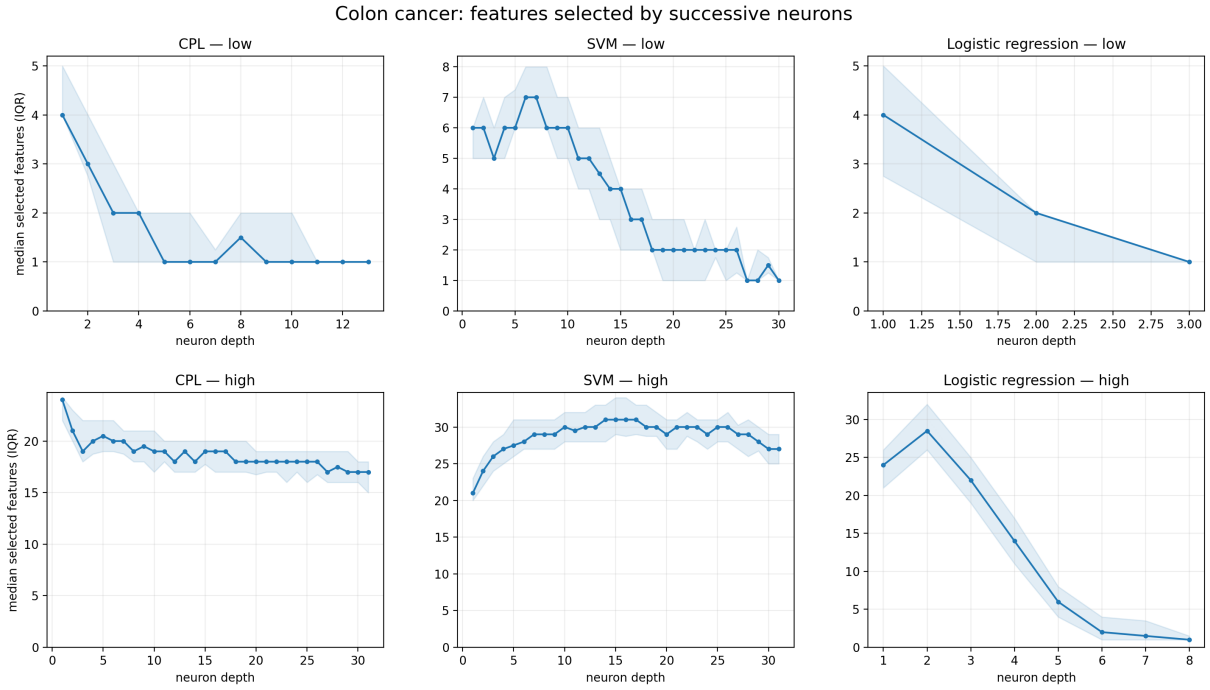
3 Trzy różne wielkości geometryczne

W interpretacji należy konsekwentnie rozróżniać trzy wielkości:

Wielkość	Wzór	Znaczenie
Szerokość formalnego pasa	$2/\|w_i\|_2$	Własność skali współczynników; zawsze dodatnia.
Odległość próbki od granicy	$\|f_i(x)\|/\|w_i\|_2$	Nieujemna siła głosu dla konkretnej próbki.
Signed geometric margin	$yf_i(x)/\|w_i\|_2$	Miara diagnostyczna; wartość ujemna oznacza błędną klasyfikację.

Szerokość formalnego pasa może rosnąć, gdy $\|w_i\|_2$ dąży do zera. Nie musi to oznaczać lepszej separacji. Późny neuron może być niemal płaski, mieć bardzo szeroki formalny pas, a jednocześnie klasyfikować obiekty testowe źle.

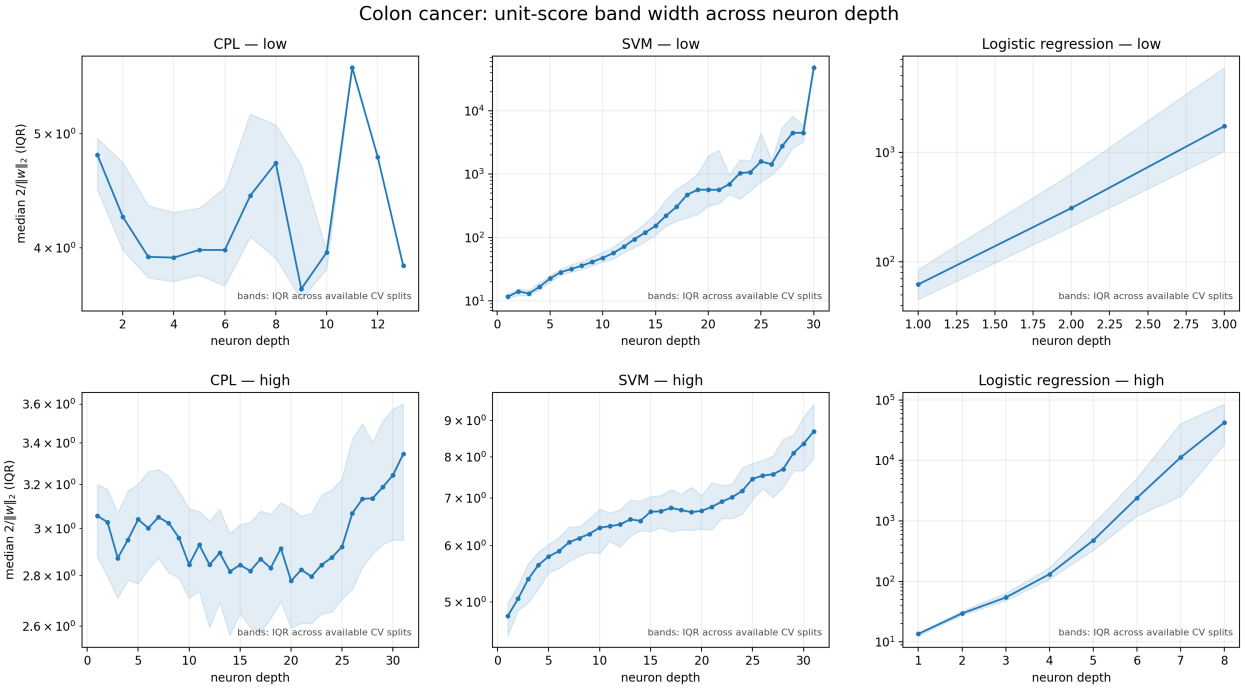
4 Liczba cech wybieranych przez kolejne neurony



Rysunek 1: Liczba cech wybranych przez kolejny neuron. Linia pokazuje medianę, a zacieniowany obszar—IQR pomiędzy splitami, w których dany neuron został zbudowany.

W reżimach low-feature CPL i regresja logistyczna szybko redukują liczbę wybieranych cech do jednej lub dwóch. SVM-low zużywa cechy wolniej: początkowo wybiera około 5–7 cech, a dopiero w późnych neuronach schodzi do pojedynczych zmiennych. W reżimie high-feature CPL utrzymuje około 17–20 cech na neuron, natomiast SVM wybiera zwykle około 27–31 cech. Regresja logistyczna high-feature szybko przechodzi od szerokich pierwszych neuronów do neuronów wykorzystujących zaledwie kilka cech. Wykres pomaga wyjaśnić różnice szerokości pasa: zanikanie normy współczynników nie musi być proporcjonalne do samej liczby niezerowych cech.

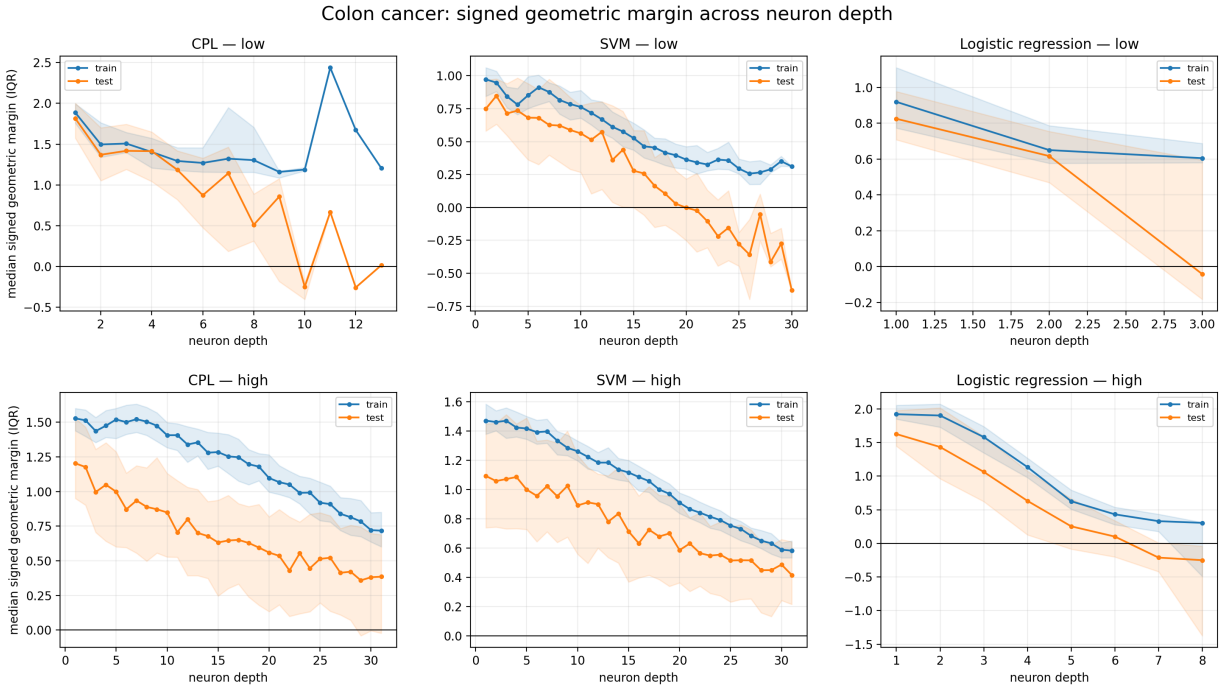
5 Szerokość formalnego pasa



Rysunek 2: Mediana szerokości formalnego pasa $2/\|w\|_2$ w kolejnych neuronach. Zacieniowany obszar przedstawia IQR pomiędzy dostępnymi splitami. Oś pionowa ma skalę logarytmiczną. Dla regresji logistycznej wielkość jest interpretowana jako unit-score band width, a nie klasyczny maksymalny margines SVM.

Dla SVM-low oraz obu konfiguracji regresji logistycznej szerokość formalnego pasa gwałtownie rośnie w późnych neuronach. Wynika to z bardzo małej normy współczynników. CPL zachowuje się inaczej: CPL-high utrzymuje względnie stabilną szerokość, a CPL-low wykazuje nieregularne wahania bez jednoznacznego trendu.

6 Signed geometric margin na train i test



Rysunek 3: Signed geometric margin na zbiorach treningowych i testowych. Linia przedstawia medianę median splitowych, a zacieniowany obszar—IQR pomiędzy splitami.

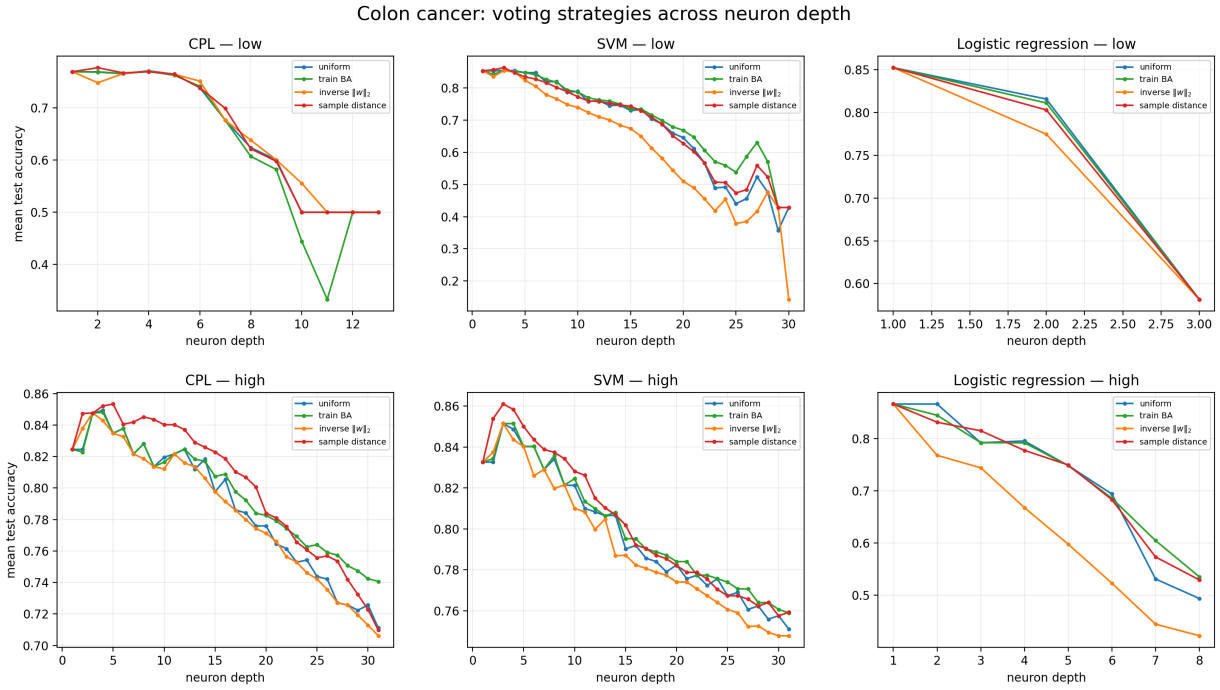
Dla każdego splitu, neuronu i obiektu obliczono

$$M_{s,k}(x) = \frac{y f_k(x)}{\|w_k\|_2}.$$

W pojedynczym foldzie testowym znajdowało się około 6–7 obiektów. Najpierw obliczano medianę po obiektach w danym splicie, a następnie medianę tych wartości po maksymalnie 100 splitach. Pas pokazuje 25. i 75. percentyl median splitowych.

Ujemna pomarańczowa linia oznacza, że w co najmniej połowie dostępnych splitów mediana signed margin na teście była ujemna. Późne neurony nadal mogą zachowywać dodatni margines treningowy, podczas gdy margines testowy spada do zera lub poniżej. Jest to sygnał pogarszającej się generalizacji i wyczerpywania stabilnego sygnału.

7 Wyniki czterech sposobów głosowania



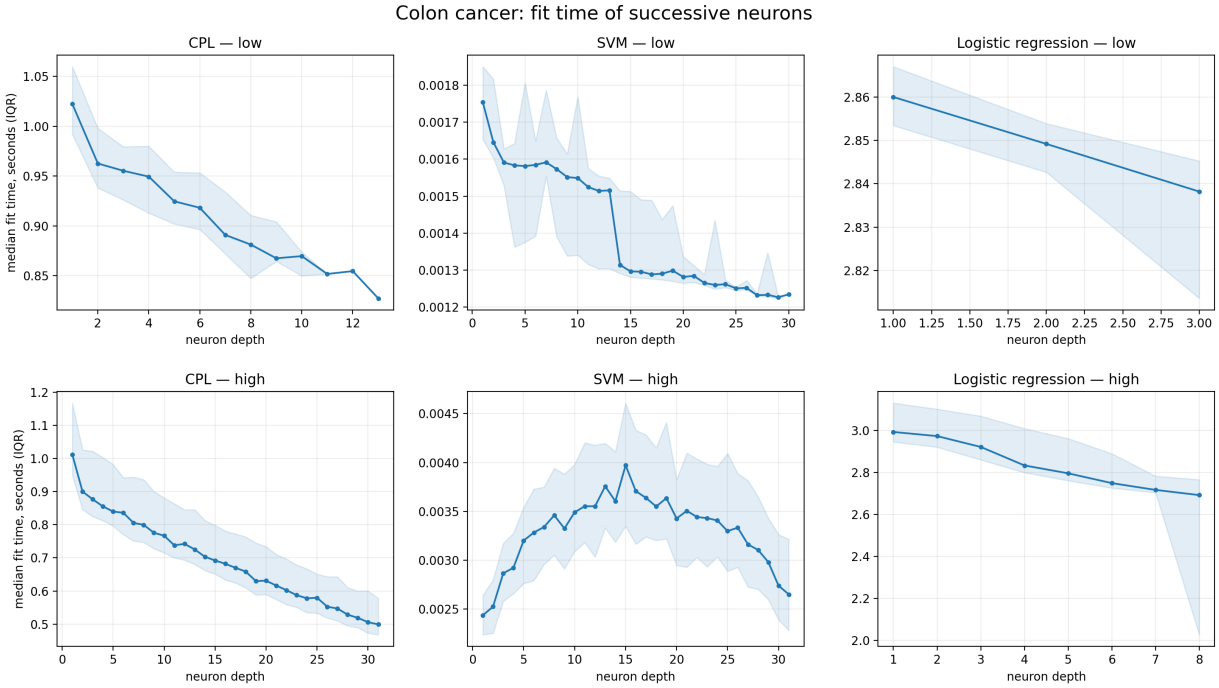
Rysunek 4: Średnia test accuracy czterech sposobów głosowania w funkcji liczby neuronów. Punkty późnych warstw należy interpretować razem z liczbą splitów, w których dana głębokość była dostępna.

Model	Reżim	Uniform best		Sample-distance best	
		Accuracy	n	Accuracy	n
CPL	low	0.7710	4	**0.7769**	2
CPL	high	0.8493	4	**0.8533**	5
SVM	low	0.8545	3	**0.8636**	3
SVM	high	0.8514	3	**0.8610**	3
Logreg	low	**0.8524**	1	0.8524	1
Logreg	high	**0.8667**	1	0.8667	1

Tabela 1: Najlepsza średnia test accuracy dla uniform i sample-distance voting. Maksimum wybierano po głębokości, dlatego tabela ma charakter opisowy, a nie jest niezależną oceną doboru głębokości.

Dla CPL najlepiej zachowuje się sample-distance voting we wczesnych warstwach. W CPL-low osiąga 0.7769 dla $n = 2$, a w CPL-high 0.8533 dla $n = 5$. Samo inverse-L2-norm weighting nie daje poprawy: premiuje późne neurony o normie bliskiej zeru, mimo że ich empiryczny margines testowy i accuracy maleją. Dla regresji logistycznej najlepszy pozostaje pierwszy neuron.

8 Czas obliczeń



Rysunek 5: Mediana czasu trenowania kolejnych neuronów; pas przedstawia IQR pomiędzy dostępnymi splitami.

Konfiguracja	Czas całego runu [s]	Przybliżony czas
SVM low	20.1	20 s
SVM high	36.8	37 s
CPL low	654.3	10.9 min
CPL high	2286.6	38.1 min
Logreg low	528.7	8.8 min
Logreg high	1798.7	30.0 min

Czas samego głosowania i obliczania metryk jest niewielki w porównaniu z dopasowaniem neuronów. Cztery strategie mogą być obliczane po treningu z zapisanych score'ów, predykcji i norm współczynników.

9 Ograniczenia interpretacji

- Późny neuron nie zawsze powstaje we wszystkich 100 splitach. Dotyczy to szczególnie CPL-low i regresji logistycznej. Końcowe punkty mogą więc opierać się na małej i selektywnej części splitów.
- Fold testowy zawiera tylko około 6–7 obiektów. Zastosowanie median ogranicza wpływ wartości odstających, ale pojedyncza mediana splitowa nadal ma charakter dyskretny i zmienny.
- Regresja logistyczna wielokrotnie osiągała limit 5000 iteracji. Wyniki logreg należy traktować jako wymagające dodatkowej kontroli zbieżności przed formułowaniem silnych wniosków.
- Wybór najlepszej głębokości na podstawie tych samych wyników CV ma charakter eksploracyjny. Do oceny procedury automatycznego wyboru głębokości potrzebna byłaby walidacja zagnieżdżona albo niezależny zbiór.

- Formalna szerokość $2/\|w\|_2$ nie jest samodzielną miarą jakości klasyfikatora, szczególnie w modelach z karą L1 i soft-margin.

10 Dyskusja teoretyczna: czego oczekiwać po kolejnych warstwach?

Niech S_k oznacza zbiór cech dostępnych dla neuronu k. Konstrukcja Complex Layers usuwa cechy wybrane wcześniej, dlatego

$$S_{k+1} \subset S_k.$$

Klasa liniowych klasyfikatorów dostępnych w kolejnej warstwie jest zatem podzbiorem klasy wcześniejszej:

$$\mathcal{H}_{k+1} \subseteq \mathcal{H}_k.$$

Hard-margin

W idealnym przypadku danych liniowo separowalnych można zdefiniować najlepszy osiągalny geometryczny margines na zbiorze treningowym jako

$$\gamma_k^\star = \max_{\substack{\|w\|_2=1 \\ w_j=0 \text{ dla } j\notin S_k}} \min_i y_i(w^\top x_i + b).$$

Ponieważ kolejna warstwa optymalizuje po mniejszym zbiorze dopuszczalnych kierunków, zachodzi

$$\gamma_{k+1}^\star \leq \gamma_k^\star.$$

W takim modelu najlepszy możliwy hard margin powinien być nierosnący wraz z głębokością. Może pozostać niezmieniony, jeżeli pozostałe cechy zawierają redundantny sygnał pozwalający skonstruować równie dobry separator. Nie powinien jednak wzrosnąć wyłącznie wskutek usunięcia dostępnych cech.

Twierdzenie dotyczy maksymalnego marginesu w zagnieżdżonych klasach hipotez, przy tej samej normalizacji i na tym samym zbiorze treningowym. Nie jest twierdzeniem o pojedynczym rozwiązaniu soft-margin ani o zachowaniu na niezależnym zbiorze testowym.

Soft-margin z regularyzacją L1

W badanym eksperymencie neurony nie rozwiązują problemu czystego hard-margin. Minimalizują funkcję postaci

$$J_k(w, b) = \|w\|_1 + C\, L_k(w, b),$$

gdzie L_k jest hinge, squared hinge albo logistic loss. Z zagnieżdżenia przestrzeni wynika jedynie, że najlepsza wartość całej funkcji celu nie może się poprawić po ograniczeniu zbioru cech:

$$\min_{(w,b)\in\mathcal{H}_{k+1}} J_k(w, b) \geq \min_{(w,b)\in\mathcal{H}_k} J_k(w, b).$$

Nie wynika z tego osobna monotoniczność straty, normy L1, normy L2 ani szerokości $2/\|w\|_2$. Optymalizator może zaakceptować większą stratę klasyfikacyjną w zamian za znacznie mniejszą normę współczynników. Możliwy jest więc przebieg

$$L_k \uparrow, \qquad \|w_k\|_2 \downarrow, \qquad \frac{2}{\|w_k\|_2} \uparrow .$$

Formalny pas staje się wtedy szerszy, lecz nie dlatego, że klasy są lepiej separowane. Funkcja decyzyjna staje się niemal płaska, a większa część próbek może znaleźć się po niewłaściwej stronie granicy.

Train a test

Argument o zagnieżdżonych klasach dotyczy optymalnego rozwiązania na ustalonym zbiorze treningowym. Nie daje monotonicznej gwarancji dla testu. W małej próbie empiryczny margines testowy może chwilowo rosnąć lub spadać wskutek zmienności foldu i niestabilności wybranych cech. Jeżeli jednak kolejne neurony systematycznie wyczerpują stabilny sygnał, naturalnym oczekiwaniem jest

$$\operatorname{median}\left(\frac{yf_k(x)}{\|w_k\|_2}\right)_{x\in\text{test}} \downarrow .$$

Jednocześnie margines treningowy może pozostawać dodatni, ponieważ neuron nadal dopasowuje strukturę obecną w foldzie treningowym. Rosnąca luka pomiędzy train i test wskazuje wtedy na coraz słabszą generalizację.

Zaobserwowane wyniki są zgodne z tym scenariuszem: signed geometric margin na teście zazwyczaj maleje, podczas gdy formalna szerokość pasa dla SVM i regresji logistycznej może silnie rosnąć. CPL-high zachowuje bardziej stabilną normę, ale również wykazuje stopniowe pogorszenie marginesu testowego. Oznacza to, że w soft-margin nie należy utożsamiać wzrostu $2/\|w\|_2$ ze wzrostem jakości separacji.

11 Wnioski

Usuwanie cech powoduje, że kolejne neurony pracują na coraz słabszej puli sygnału. Empiryczny signed geometric margin na teście zazwyczaj maleje szybciej niż margines treningowy. Jednocześnie formalna szerokość pasa może rosnąć wskutek zanikania normy współczynników. Wyjaśnia to, dlaczego ważenie wyłącznie przez $1/\|w\|_2$ nie poprawia wyników.

Najbardziej obiecującą strategią dla CPL jest sample-distance voting, szczególnie w płytkiej warstwie liczącej około 2–5 neuronów. Łączy ono kierunek głosu z odległością konkretnej próbki od granicy, dzięki czemu nie interpretuje automatycznie małej normy współczynników jako wysokiej jakości neuronu.