Eksperymenty z ważonym głosowaniem i marginesami

Complex Layers na zbiorze colon cancer

Jerzy Krawczuk

29 września 2026

Streszczenie

Raport podsumowuje dodatkowe eksperymenty wykonane po wysłaniu artykułu do recenzji. Nie stanowią one zmiany wysłanej wersji artykułu. Porównano sześć sposobów agregacji głosów kolejnych neuronów oraz przeanalizowano szerokość pasa i empiryczny signed margin w geometriach L_2 i L_∞. Eksperyment przeprowadzono na zbiorze colon cancer za pomocą 10-krotnej walidacji krzyżowej powtórzonej 10 razy, osobno dla modeli CPL, SVM i regresji logistycznej w reżimach low-, high- oraz high-top5.

1 Konfiguracja eksperymentu

Zbiór colon cancer zawiera 62 obiekty, 2000 cech ekspresji genów i dwie klasy diagnostyczne. Dla każdej konfiguracji zastosowano repeated stratified cross-validation: 10 foldów i 10 powtórzeń, łącznie 100 splitów. Standaryzację dopasowywano wyłącznie na części treningowej każdego splitu. Kolejny neuron otrzymywał pulę cech pomniejszoną o cechy wybrane przez neurony wcześniejsze.

Użyto tych samych parametrów regularyzacji co w eksperymentach artykułu:

Model	C_{low}	C_{high}	$C_{\text{high-top5}}$
CPL	2.0	8.0	8.0
SVM	1.3	5.2	5.2
Logistic regression	3.4	5.2	5.2

Wszystkie modele stosują regularyzację L1. Różnią się funkcją straty: CPL używa hinge loss rozwiązywanego jako program liniowy, SVM używa squared hinge loss, a regresja logistyczna—logistic loss. Norma L2 nie jest karą optymalizacyjną; służy do późniejszego pomiaru geometrii euklidesowej. Ponieważ karą we wszystkich modelach jest L1, równolegle analizowana jest naturalnie dualna geometria L_∞.

Reżim high-top5 używa tej samej wartości C co high, lecz ogranicza każdy neuron do maksymalnie pięciu cech. Najpierw dopasowywany jest zwykły model L1 na całej aktualnie dostępnej puli cech. Jeżeli ma więcej niż pięć niezerowych współczynników, wybieranych jest pięć największych wartości $|w_j|$ (remisy rozstrzyga indeks cechy), po czym ten sam typ modelu jest ponownie dopasowywany tylko na tych cechach. Z puli dla następnego neuronu usuwa się cechy aktywne po reficie. Jest to deterministyczna heurystyka "co najwyżej 5", a nie rozwiązanie dokładnego problemu optymalizacyjnego z warunkiem $\|w\|_0 = 5$.

2 Sześć sposobów głosowania

Niech wynik liniowy neuronu i będzie równy

$$f_i(x) = w_i^\top x + b_i.$$

Porównano następujące strategie:

1. **Uniform voting**: każdy neuron oddaje głos o tej samej wadze.
2. **Training-BA voting**: stała waga neuronu jest wyznaczana wyłącznie z jego balanced accuracy na foldzie treningowym:
$$q_i = \max(0, \mathrm{BA}_i^{\mathrm{train}} - 0.5), \qquad \alpha_i = \frac{q_i}{\sum_j q_j}.$$
Jeżeli wszystkie q_i są równe zero, stosowane są wagi jednakowe.
3. **Inverse-L2-norm voting**: propozycja oparta na euklidesowej szerokości unit-score pasa. Stała waga neuronu jest proporcjonalna do
$$\alpha_i \propto \frac{1}{\|w_i\|_2}.$$
4. **Sample-distance L_2 voting**: waga zależy od klasyfikowanego obiektu. Siła głosu wynosi
$$D_i(x) = \frac{|f_i(x)|}{\|w_i\|_2},$$
a końcowa decyzja jest równoważna znakowi sumy
$$\sum_i \frac{f_i(x)}{\|w_i\|_2}.$$
5. **Inverse-L1-norm voting**: odpowiednik stałego ważenia w geometrii dualnej do regularyzacji L1:
$$\alpha_i \propto \frac{1}{\|w_i\|_1}.$$
6. **Sample-distance L_∞ voting**: siła głosu jest odległością próbki od hiperpłaszczyzny mierzoną normą L_∞:
$$D_i^{(\infty)}(x) = \frac{|f_i(x)|}{\|w_i\|_1}, \qquad \widehat{y} = \operatorname{sign}\left(\sum_i \frac{f_i(x)}{\|w_i\|_1}\right).$$

Wszystkie strategie są obliczane z tych samych dopasowanych neuronów. Zmiana sposobu głosowania nie wymaga ponownego treningu i nie korzysta z etykiet testowych.

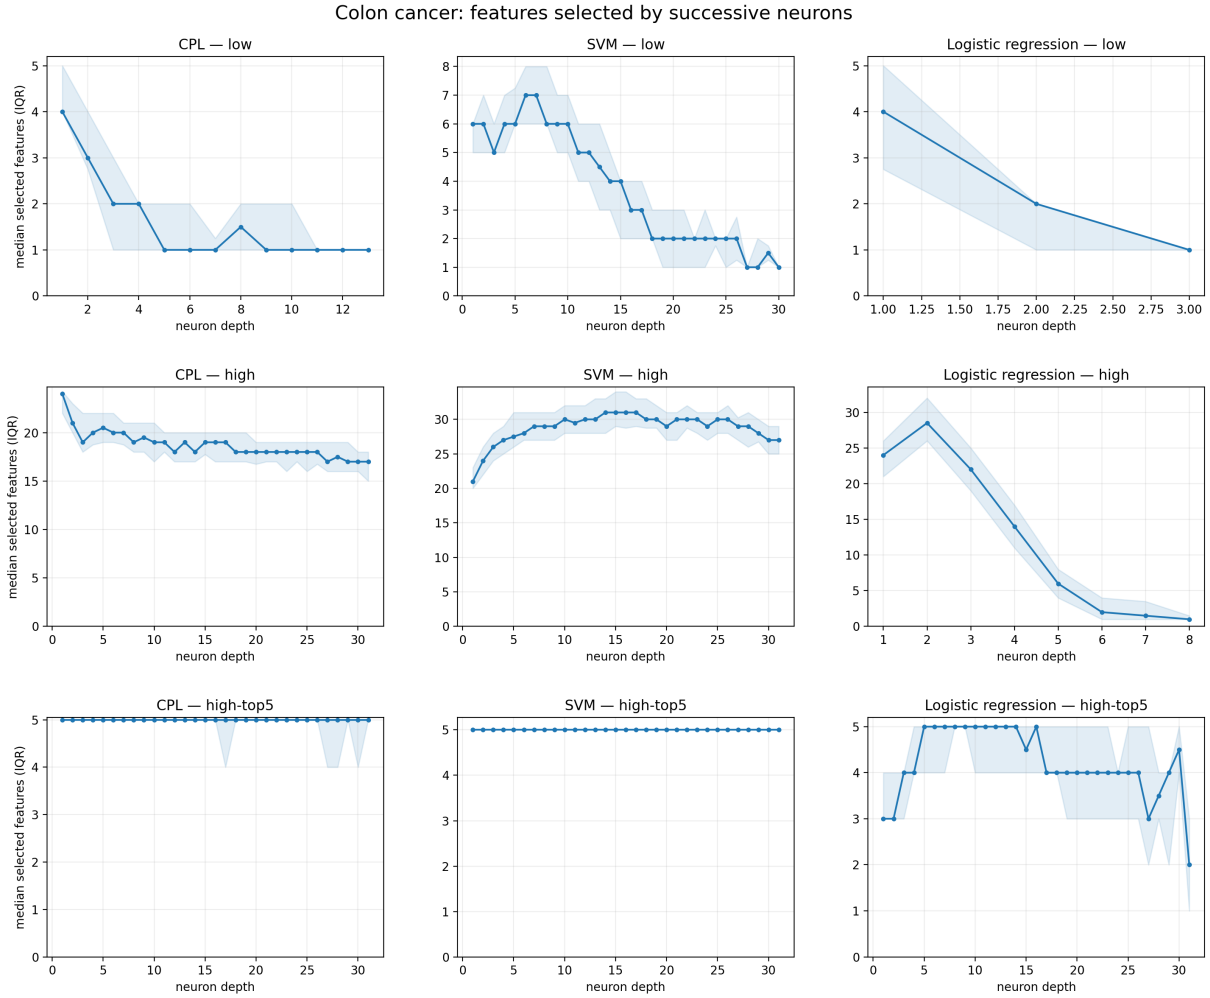
3 Trzy wielkości w dwóch geometriach

Jeżeli odległość w przestrzeni wejściowej mierzymy normą L_p, w mianowniku pojawia się norma dualna L_q, gdzie $1/p+1/q = 1$. Analizujemy dwie pary: $(p, q) = (2, 2)$ oraz $(p, q) = (\infty, 1)$. W obu geometriach należy konsekwentnie rozróżniać trzy wielkości:

Wielkość	Wzór	Znaczenie
Szerokość unit-score pasa	$2/\|w_i\|_q$	Własność skali współczynników; zawsze dodatnia.
Odległość próbki od granicy	$\|f_i(x)\|/\|w_i\|_q$	Nieujemna siła głosu dla konkretnej próbki.
Signed margin	$yf_i(x)/\|w_i\|_q$	Wartość ujemna oznacza błędną klasyfikację.

Dla $p = 2$ otrzymujemy mianownik $\|w\|_2$ i odległość euklidesową. Dla $p = \infty$ mianownikiem jest $\|w\|_1$, czyli dokładnie norma używana przez nasze modele jako kara. Szerokość unit-score pasa może rosnąć, gdy odpowiednia norma wag dąży do zera. Nie musi to oznaczać lepszej separacji: późny neuron może być niemal płaski, mieć bardzo szeroki pas, a jednocześnie klasyfikować obiekty testowe źle.

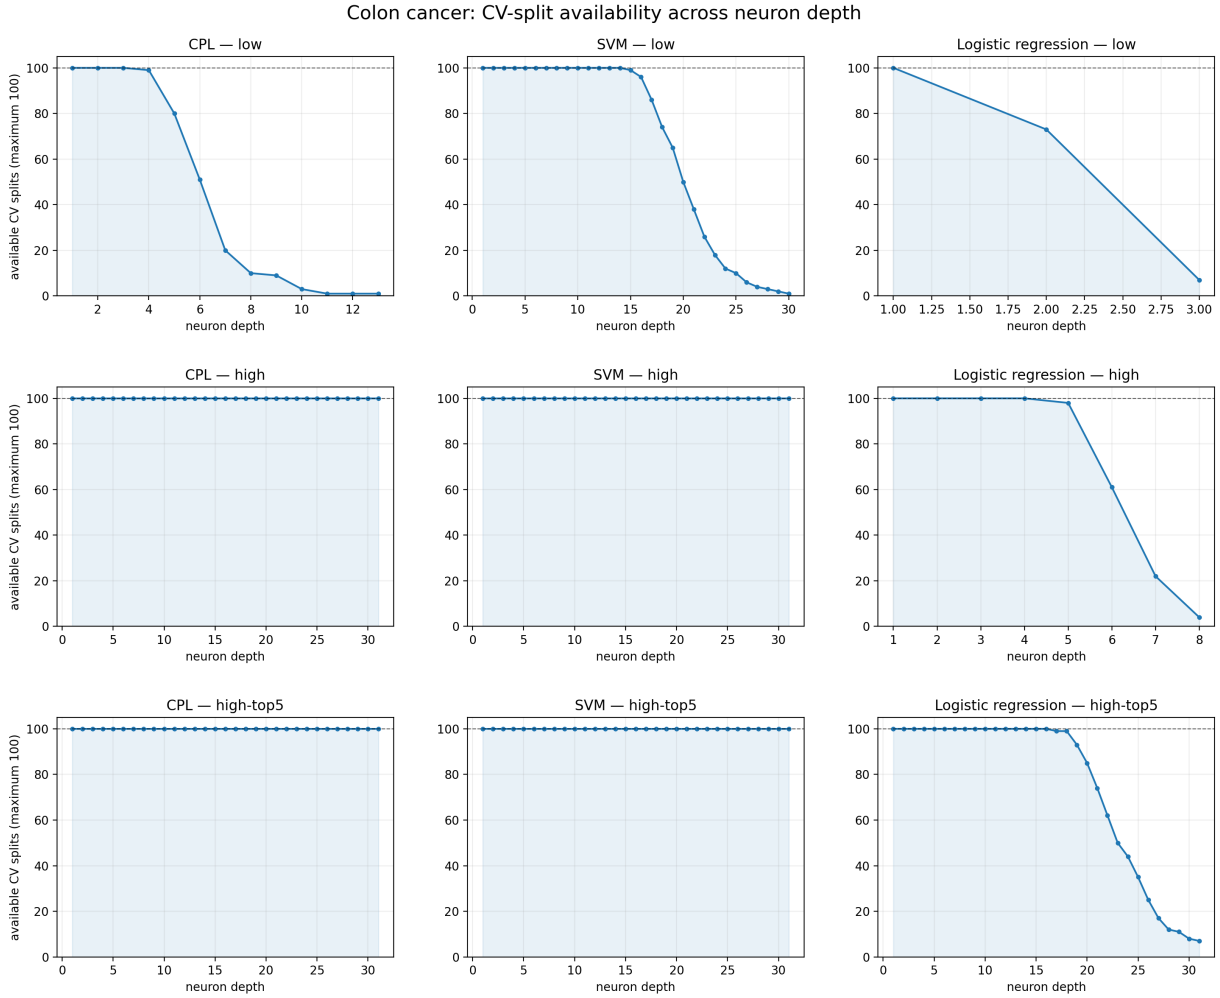
4 Liczba cech wybieranych przez kolejne neurony



Rysunek 1: Liczba cech wybranych przez kolejny neuron. Linia pokazuje medianę, a zacieniowany obszar—IQR pomiędzy splitami, w których dany neuron został zbudowany.

W reżimach low-feature CPL i regresja logistyczna szybko redukują liczbę wybieranych cech do jednej lub dwóch. SVM-low zużywa cechy wolniej: początkowo wybiera około 5–7 cech, a dopiero w późnych neuronach schodzi do pojedynczych zmiennych. W reżimie high-feature CPL utrzymuje około 17–20 cech na neuron, natomiast SVM wybiera zwykle około 27–31 cech. Regresja logistyczna high-feature szybko przechodzi od szerokich pierwszych neuronów do neuronów wykorzystujących zaledwie kilka cech. W high-top5 mediana wynosi zwykle dokładnie pięć cech dla CPL i SVM; regresja logistyczna częściej pozostawia 3–5, ponieważ refit L1 może ponownie wyzerować część współczynników. Wykres pomaga wyjaśnić różnice szerokości pasa: zanikanie normy współczynników nie musi być proporcjonalne do samej liczby niezerowych cech.

5 Dostępność splitów na kolejnych głębokościach

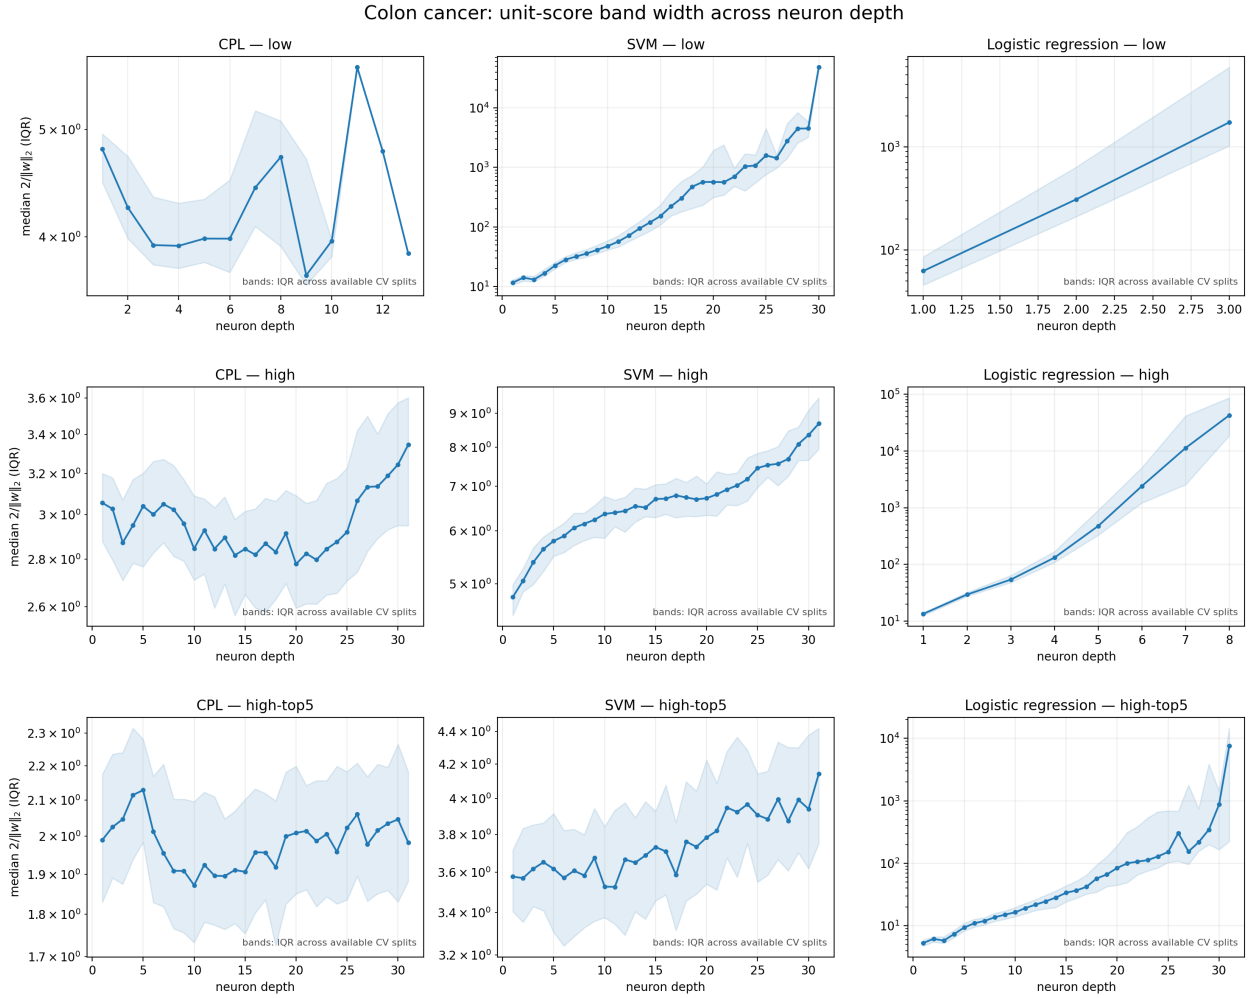


Rysunek 2: Liczba splitów CV, w których zbudowano neuron o danej głębokości. Pozioma linia przerywana oznacza pełne 100 splitów (10 foldów × 10 powtórzeń).

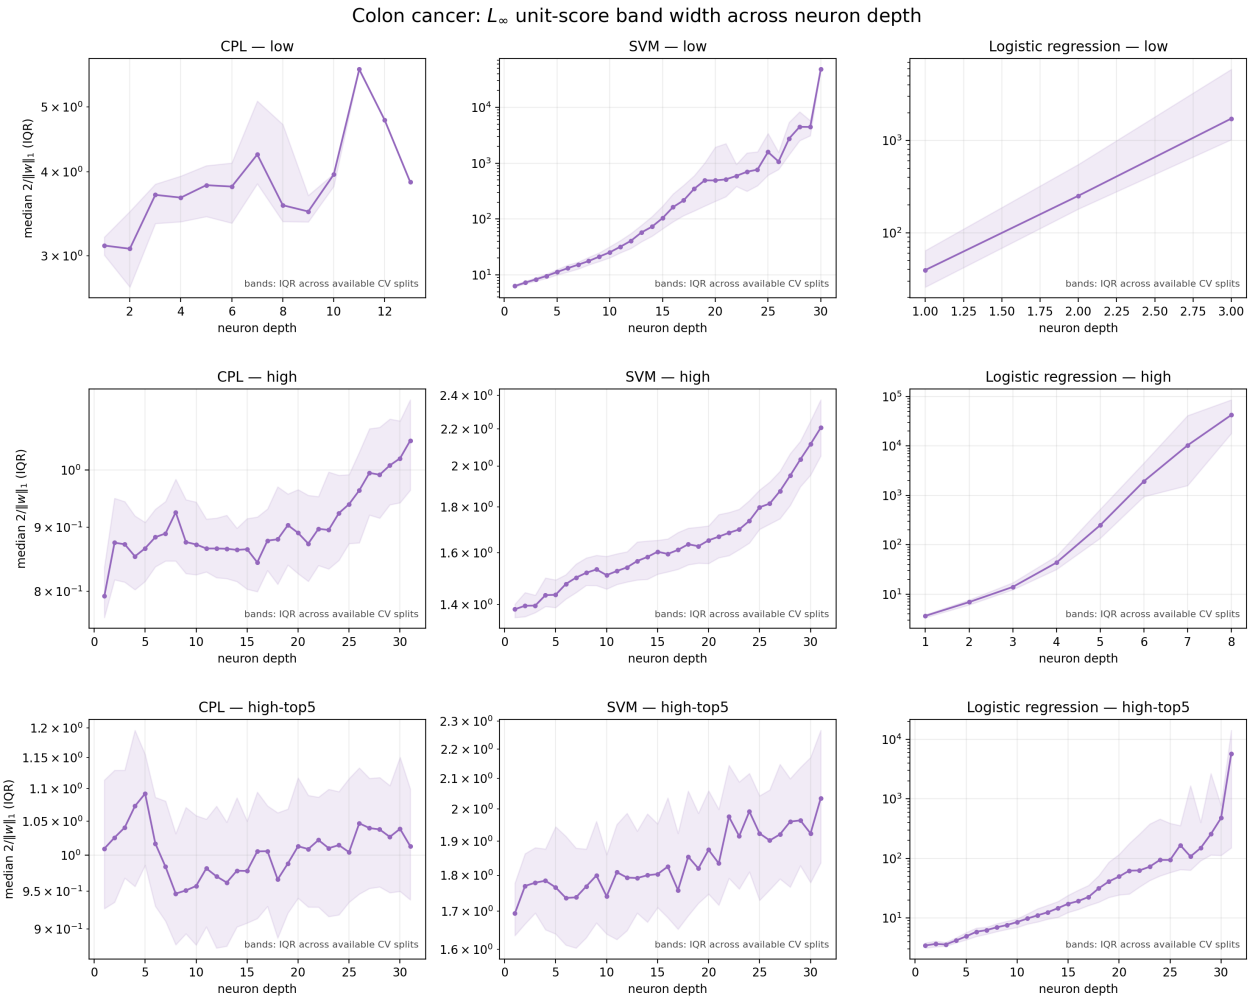
Dostępność na poziomie k zdefiniowano jako liczbę różnych splitów, dla których w szczegółowych wynikach istnieje rekord z `n_neuron`$= k$. Wszystkie mediany, IQR oraz średnie accuracy pokazane dalej dla poziomu k są obliczone wyłącznie z tych dostępnych splitów, a nie zawsze ze stałego zbioru 100 realizacji.

Spadek tej krzywej oznacza, że po usunięciu cech wcześniejsze neurony wyczerpały pulę wystarczającą do zbudowania następnego neuronu. Dlatego końcowe punkty CPL-low, SVM-low i regresji logistycznej opisują selektywną podgrupę splitów i mają znacznie większą niepewność. Nie należy porównywać ich z wcześniejszymi punktami tak, jakby wszystkie były oparte na tej samej liczbie realizacji. CPL-high, SVM-high oraz ich warianty high-top5 zachowują pełne 100 splitów aż do poziomu 31. Logreg-high-top5 ma pełne pokrycie do poziomu 16, a potem stopniowy spadek. Dokładne liczby i regułę zatrzymania podano w suplemencie.

6 Szerokość unit-score pasa



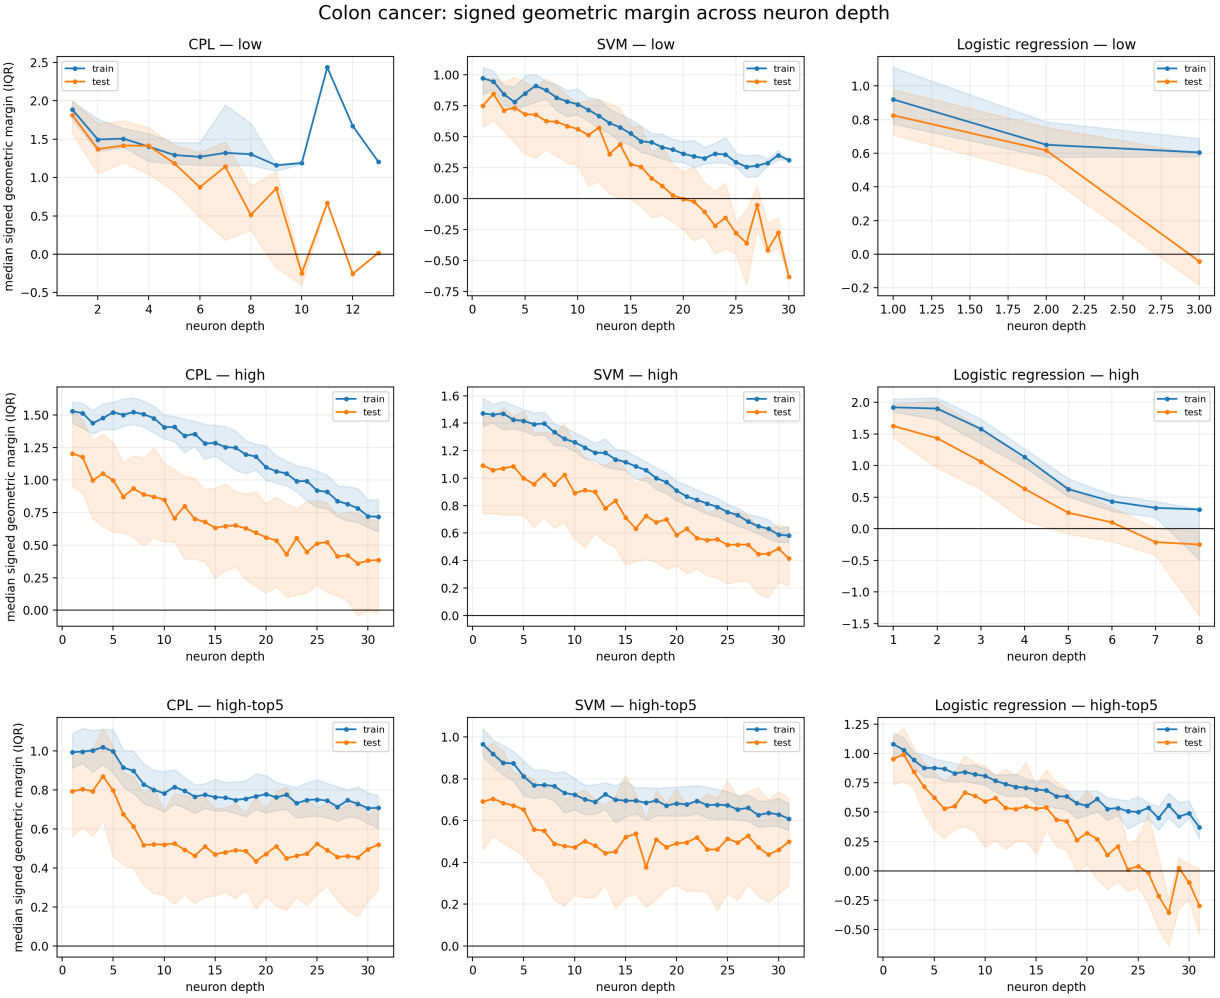
Rysunek 3: Mediana euklidesowej szerokości unit-score pasa $2/\|w\|_2$ w kolejnych neuronach. Zacieniowany obszar przedstawia IQR pomiędzy dostępnymi splitami. Oś pionowa ma skalę logarytmiczną. Dla regresji logistycznej wielkość jest interpretowana jako unit-score band width, a nie klasyczny maksymalny margines SVM.



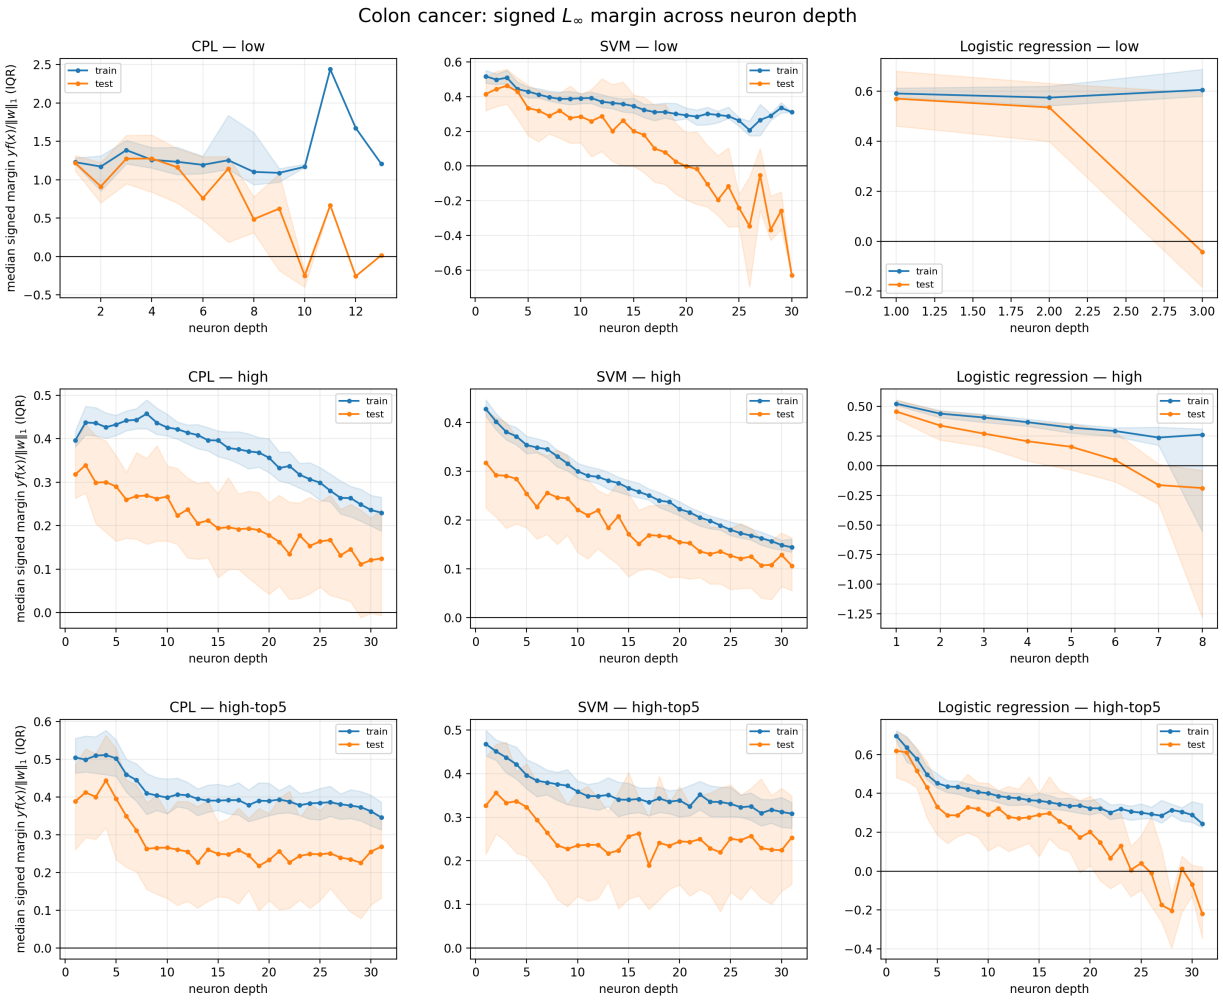
Rysunek 4: Mediana szerokości unit-score pasa $2/\|w\|_1$, czyli szerokości w geometrii L_∞ naturalnie dualnej do zastosowanej regularyzacji L1. Pas przedstawia IQR, a oś pionowa ma skalę logarytmiczną.

Dla SVM-low oraz konfiguracji regresji logistycznej szerokość gwałtownie rośnie w późnych neuronach w obu geometriach. Wynika to z zanikania norm współczynników, a nie z poprawy separacji. CPL zachowuje się inaczej: CPL-high pozostaje względnie stabilny w geometrii euklidesowej, natomiast $2/\|w\|_1$ zaczyna rosnąć w późnych neuronach. CPL-low wykazuje nieregularne wahania w obu ujęciach. Wiersz high-top5 pozwala oddzielić wpływ samej liczby cech od wpływu funkcji straty: przy tym samym limicie pięciu cech przebiegi trzech modeli nadal wyraźnie się różnią.

7 Signed geometric margin na train i test



Rysunek 5: Signed geometric margin na zbiorach treningowych i testowych. Linia przedstawia medianę median splitowych, a zacieniowany obszar—IQR pomiędzy splitami.



Rysunek 6: Signed margin $yf(x)/\|w\|_1$ na zbiorach treningowych i testowych, czyli odległość ze znakiem w geometrii L_∞. Linia przedstawia medianę median splitowych, a pas—IQR.

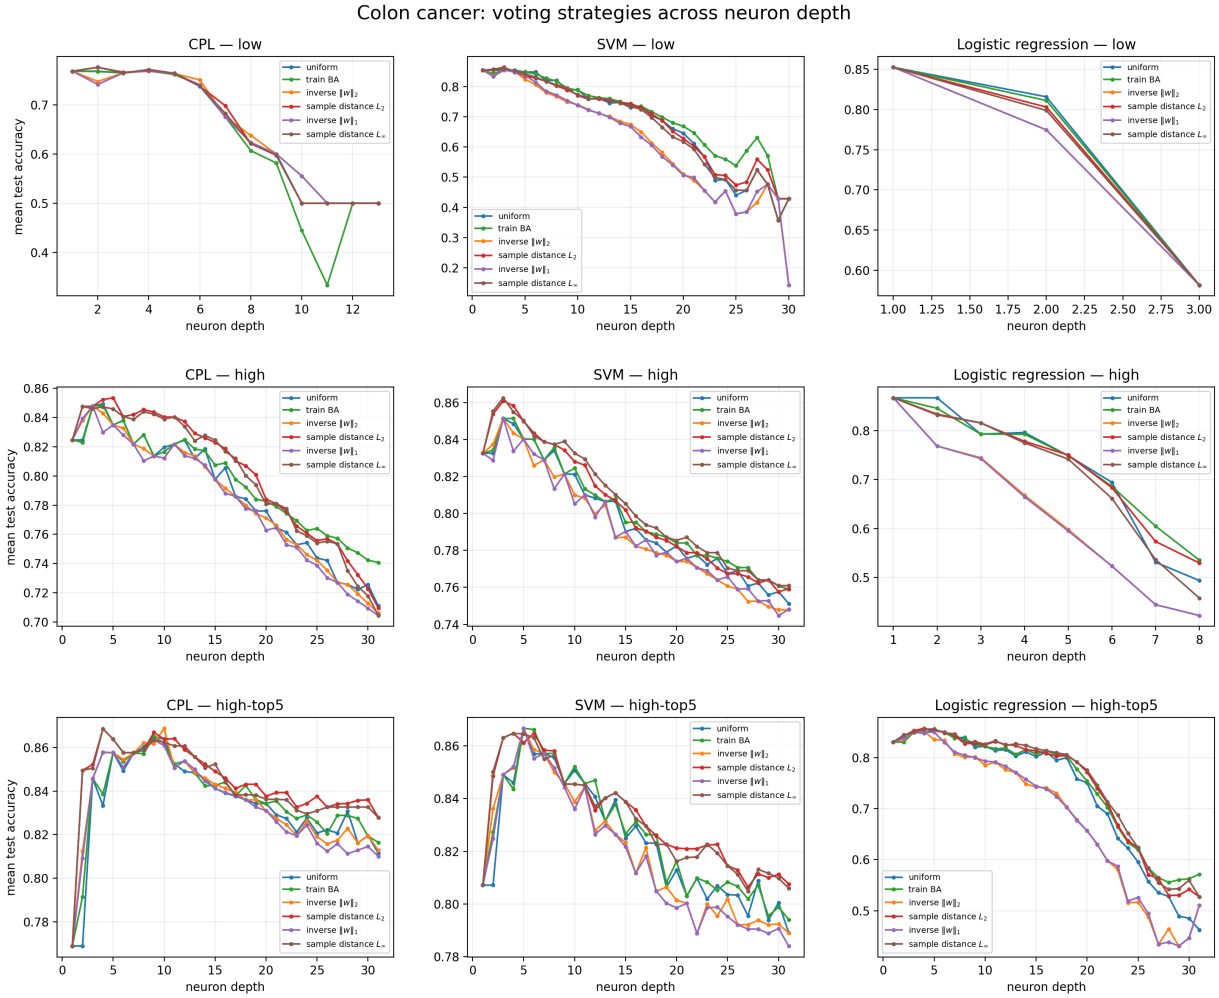
Dla każdego splitu, neuronu i obiektu obliczono

$$M^{(2)}_{s,k}(x) = \frac{yf_k(x)}{\|w_k\|_2}, \qquad M^{(\infty)}_{s,k}(x) = \frac{yf_k(x)}{\|w_k\|_1}.$$

W pojedynczym foldzie testowym znajdowało się około 6–7 obiektów. Najpierw obliczano medianę po obiektach w danym splicie, a następnie medianę tych wartości po maksymalnie 100 splitach. Pas pokazuje 25. i 75. percentyl median splitowych.

Ujemna pomarańczowa linia oznacza, że w co najmniej połowie dostępnych splitów mediana signed margin na teście była ujemna. Późne neurony nadal mogą zachowywać dodatni margines treningowy, podczas gdy margines testowy spada do zera lub poniżej. Jest to sygnał pogarszającej się generalizacji i wyczerpywania stabilnego sygnału.

8 Wyniki sześciu sposobów głosowania



Rysunek 7: Średnia test accuracy sześciu sposobów głosowania w funkcji liczby neuronów. Punkty późnych warstw należy interpretować razem z liczbą splitów, w których dana głębokość była dostępna.

Model	Reżim	Uniform		Sample L_2		Sample L_∞	
		Accuracy	n	Accuracy	n	Accuracy	n
CPL	low	0.7710	4	**0.7769**	2	**0.7769**	2
CPL	high	0.8493	4	**0.8533**	5	0.8474	2
SVM	low	0.8545	3	**0.8636**	3	0.8605	3
SVM	high	0.8514	3	0.8610	3	**0.8626**	3
Logreg	low	**0.8524**	1	0.8524	1	0.8524	1
Logreg	high	**0.8667**	1	0.8667	1	0.8667	1
CPL	high-top5	0.8650	9	**0.8686**	4	**0.8686**	4
SVM	high-top5	**0.8667**	5	0.8648	4	0.8648	4
Logreg	high-top5	0.8545	5	**0.8574**	4	0.8560	5

Tabela 1: Najlepsza średnia test accuracy dla uniform oraz sample-distance voting w geometriach L_2 i L_∞. Maksimum wybierano po głębokości, dlatego tabela ma charakter opisowy.

Dla CPL-low oba sample-distance voting osiągają 0.7769 przy $n = 2$. Dla CPL-high lepsza jest geometria L_2 (0.8533 przy $n = 5$), natomiast dla SVM-high nieznacznie wyższe maksimum daje

geometria L_∞ (0.8626 przy $n = 3$). Zgodność L_∞ z regularyzacją L1 nie gwarantuje zatem lepszej predykcji. Stałe ważenie samą odwrotnością normy—zarówno L1, jak i L2—nie daje systematycznej poprawy. Dla regresji logistycznej najlepszy pozostaje pierwszy neuron.

High-top5 zmienia obraz CPL: pojedynczy neuron jest słabszy, lecz agregacja szybko rośnie i osiąga 0.8686 przy czterech neuronach dla obu wariantów sample-distance. Jest to najwyższe opisowe maksimum CPL w tym eksperymencie i hipoteza warta sprawdzenia na innych zbiorach. Dla SVM ograniczenie do pięciu cech nie daje przewagi ważenia nad uniform, a dla logreg poprawa sample-distance L_2 jest niewielka.

Analiza sparowana wariantu L_2 względem uniform voting (suplement) wskazuje, że przewaga jest wyraźniejsza dla CPL-high, natomiast dla CPL-low pozostaje niepewna.

Koszt eksperymentu wynika niemal w całości z trenowania neuronów; przeliczenie sześciu strategii głosowania na podstawie zapisanych wyników jest pomijalne. Szczegółowe czasy podano w suplemencie.

9 Ograniczenia interpretacji

- Późny neuron nie zawsze powstaje we wszystkich 100 splitach. Dotyczy to szczególnie CPL-low i regresji logistycznej. Końcowe punkty mogą więc opierać się na małej i selektywnej części splitów.
- Fold testowy zawiera tylko około 6–7 obiektów. Zastosowanie median ogranicza wpływ wartości odstających, ale pojedyncza mediana splitowa nadal ma charakter dyskretny i zmienny.
- Regresja logistyczna zgłaszała ostrzeżenia o osiągnięciu limitu iteracji. Wyniki logreg wymagają dodatkowej ostrożności; dla high-top5 diagnostykę pierwszego dopasowania i refitu zapisano osobno, a szczegóły podano w suplemencie.
- Wybór najlepszej głębokości na podstawie tych samych wyników CV ma charakter eksploracyjny. Do oceny procedury automatycznego wyboru głębokości potrzebna byłaby walidacja zagnieżdżona albo niezależny zbiór.
- Formalna szerokość $2/\|w\|_2$ nie jest samodzielną miarą jakości klasyfikatora, szczególnie w modelach z karą L1 i soft-margin.

10 Dyskusja teoretyczna: czego oczekiwać po kolejnych warstwach?

Niech S_k oznacza zbiór cech dostępnych dla neuronu k. Konstrukcja Complex Layers usuwa cechy wybrane wcześniej, dlatego

$$S_{k+1} \subset S_k.$$

Klasa liniowych klasyfikatorów dostępnych w kolejnej warstwie jest zatem podzbiorem klasy wcześniejszej:

$$\mathcal{H}_{k+1} \subseteq \mathcal{H}_k.$$

Hard-margin

W idealnym przypadku danych liniowo separowalnych można zdefiniować najlepszy osiągalny margines w dowolnej ustalonej geometrii L_p jako

$$\gamma^\star_{k,p} = \max_{\substack{\|w\|_q=1 \\ w_j=0 \text{ dla } j\notin S_k}} \min_i y_i(w^\top x_i + b).$$

Norma L_q jest dualna do L_p. Dla geometrii euklidesowej $q = 2$, a dla geometrii L_∞ mamy $q = 1$. Ponieważ kolejna warstwa optymalizuje po mniejszym zbiorze dopuszczalnych kierunków, w obu przypadkach zachodzi

$$\gamma^\star_{k+1,p} \leq \gamma^\star_{k,p}.$$

W takim modelu najlepszy możliwy hard margin powinien być nierosnący wraz z głębokością. Może pozostać niezmieniony, jeżeli pozostałe cechy zawierają redundantny sygnał pozwalający skonstruować równie dobry separator. Nie powinien jednak wzrosnąć wyłącznie wskutek usunięcia dostępnych cech.

Twierdzenie dotyczy maksymalnego marginesu w zagnieżdżonych klasach hipotez, przy tej samej normalizacji i na tym samym zbiorze treningowym. Nie jest twierdzeniem o pojedynczym rozwiązaniu soft-margin ani o zachowaniu na niezależnym zbiorze testowym.

Soft-margin z regularyzacją L1

W badanym eksperymencie neurony nie rozwiązują problemu czystego hard-margin. Minimalizują funkcję postaci

$$J_k(w, b) = \|w\|_1 + C\, L_k(w, b),$$

gdzie L_k jest hinge, squared hinge albo logistic loss. Z zagnieżdżenia przestrzeni wynika jedynie, że najlepsza wartość całej funkcji celu nie może się poprawić po ograniczeniu zbioru cech:

$$\min_{(w,b)\in\mathcal{H}_{k+1}} J_k(w, b) \geq \min_{(w,b)\in\mathcal{H}_k} J_k(w, b).$$

Nie wynika z tego osobna monotoniczność straty, normy L1, normy L2 ani żadnej z analizowanych szerokości $2/\|w\|_q$. Optymalizator może zaakceptować większą stratę klasyfikacyjną w zamian za znacznie mniejszą normę współczynników. Dla $q \in \{1, 2\}$ możliwy jest więc przebieg

$$L_k \uparrow, \qquad \|w_k\|_q \downarrow, \qquad \frac{2}{\|w_k\|_q} \uparrow .$$

Formalny pas staje się wtedy szerszy, lecz nie dlatego, że klasy są lepiej separowane. Funkcja decyzyjna staje się niemal płaska, a większa część próbek może znaleźć się po niewłaściwej stronie granicy.

Train a test

Argument o zagnieżdżonych klasach dotyczy optymalnego rozwiązania na ustalonym zbiorze treningowym. Nie daje monotonicznej gwarancji dla testu. W małej próbie empiryczny margines testowy może chwilowo rosnąć lub spadać wskutek zmienności foldu i niestabilności wybranych cech. Jeżeli jednak kolejne neurony systematycznie wyczerpują stabilny sygnał, naturalnym oczekiwaniem jest

$$\operatorname{median}\left(\frac{y f_k(x)}{\|w_k\|_q}\right)_{x\in\text{test}} \downarrow .$$

Jednocześnie margines treningowy może pozostawać dodatni, ponieważ neuron nadal dopasowuje strukturę obecną w foldzie treningowym. Rosnąca luka pomiędzy train i test wskazuje wtedy na coraz słabszą generalizację.

Zaobserwowane wyniki są zgodne z tym scenariuszem: signed geometric margin na teście zazwyczaj maleje, podczas gdy szerokość pasa dla SVM i regresji logistycznej może silnie rosnąć w obu geometriach. CPL-high zachowuje bardziej stabilne normy, ale również wykazuje stopniowe pogorszenie marginesu testowego. Oznacza to, że w soft-margin nie należy utożsamiać wzrostu $2/\|w\|_q$ ze wzrostem jakości separacji.

11 Główne obserwacje i hipotezy badawcze

Poniższe punkty zbierają najważniejsze wnioski w formie, która może stanowić punkt wyjścia do dalszych eksperymentów. Należy rozróżnić wniosek wynikający z konstrukcji matematycznej od obserwacji empirycznych na jednym zbiorze danych:

1. **Nierosnący optymalny hard margin (wynik teoretyczny).** Przy ustalonym zbiorze treningowym, tej samej normalizacji i zagnieżdżonych zbiorach dostępnych cech najlepszy osiągalny hard margin nie może wzrosnąć w następnej warstwie. Usunięcie cech zawęża klasę dopuszczalnych separatorów.

2. **Rosnący formalny pas nie musi oznaczać lepszego separatora (mechanizm soft-margin).** Przy regularyzacji L1 optymalizator może zaakceptować większą stratę w zamian za mniejszą normę współczynników. Wtedy $2/\|w\|_q$ może rosnąć, chociaż accuracy oraz empiryczny signed margin maleją. Szczególnie szeroki pas może więc wskazywać na neuron niemal płaski, a nie na mocny klasyfikator.

3. **Margines testowy pogarsza się szybciej niż treningowy (obserwacja empiryczna).** W badanych konfiguracjach późne neurony często zachowują dodatni signed margin na treningu, podczas gdy mediana na teście zbliża się do zera lub staje się ujemna. Jest to zgodne z hipotezą stopniowego wyczerpywania stabilnego sygnału i narastania luki generalizacyjnej.

4. **Dostępność późnych neuronów jest selektywna (obserwacja i problem metodologiczny).** Nie każdy split pozwala zbudować taką samą liczbę neuronów. Statystyki późnych warstw CPL-low, SVM-low i regresji logistycznej są zatem obliczane na coraz mniejszej, niereprezentatywnej podgrupie splitów. Coverage powinno być zawsze raportowane razem z krzywymi zależnymi od głębokości.

5. **Ważenie samą odwrotnością normy może premiować słabe neurony (obserwacja empiryczna).** Waga proporcjonalna do $1/\|w\|_q$ staje się bardzo duża, gdy współczynniki późnego neuronu zanikają. Eksperyment pokazuje, że taka szerokość formalnego pasa nie jest wystarczającą miarą wiarygodności głosu i może pogarszać wynik agregacji.

6. **Sample-distance voting jest obiecujące dla płytkich CPL (wynik pilotażowy).** W CPL-low warianty L_2 i L_∞ dają to samo maksimum, natomiast w CPL-high lepszy jest wariant $f_i(x)/\|w_i\|_2$. Dla SVM-high nieznacznie lepszy jest wariant L_∞. Wyniki wymagają potwierdzenia na innych zbiorach oraz wyboru głębokości wykonywanego w wewnętrznej walidacji.

7. **Stały budżet cech może poprawić CPL (obserwacja empiryczna).** W high-top5 CPL osiąga 0.8686 przy czterech neuronach, więcej niż w naturalnym reżimie high. Ograniczenie redukuje zużycie cech przez pojedynczy neuron i pozwala budować kolejne, nadal użyteczne głosy. Ponieważ top-5 jest heurystyką ocenioną na tym samym zbiorze, wynik należy traktować jako hipotezę, nie potwierdzoną przewagę metody.

Pierwsze dwa punkty opisują ogólny mechanizm geometryczny, natomiast punkty 3–7 są hipotezami empirycznymi wyprowadzonymi z eksperymentu colon cancer. Nie należy jeszcze traktować ich jako wyników uniwersalnych; naturalnym kolejnym krokiem są dane syntetyczne o kontrolowanej redundancji i szumie oraz porównanie na większej rodzinie zbiorów wysokowymiarowych.

12 Wnioski

Usuwanie cech powoduje, że kolejne neurony pracują na coraz słabszej puli sygnału. Empiryczny signed geometric margin na teście zazwyczaj maleje szybciej niż margines treningowy. Jednocześnie

formalna szerokość pasa może rosnąć wskutek zanikania normy współczynników w geometrii L_2 lub L_∞. Wyjaśnia to, dlaczego ważenie wyłącznie przez odwrotność normy nie poprawia systematycznie wyników.

Najbardziej obiecującą strategią dla CPL jest sample-distance voting, szczególnie w płytkiej warstwie liczącej około 2–5 neuronów. High-top5 daje najwyższe opisowe maksimum CPL i sugeruje, że kontrolowanie budżetu cech może być równie istotne jak sposób głosowania. Wyniki nie wskazują jednak jednej uniwersalnie najlepszej geometrii: L_2 wygrywa dla CPL-high, L_∞ nieznacznie dla SVM-high, a dla CPL-low i CPL-high-top5 oba warianty remisują.

A Suplement techniczny

Ta część gromadzi informacje potrzebne do reprodukcji i audytu wyników, bez przerywania głównej narracji raportu.

A.1 Szczegóły reprodukcyjne

Podziały wygenerowano przez `RepeatedStratifiedKFold` z `random_state=42`. Każdą cechę standaryzowano osobno w splicie za pomocą średniej i odchylenia standardowego ($ddof = 1$) obliczonych tylko na foldzie treningowym; te same parametry stosowano następnie do foldu testowego. Wszystkie modele korzystały z balanced sample weights. Maksymalna liczba neuronów wynosiła 31, próg uznania współczynnika za niezerowy 10^{-8}, a limit iteracji modeli scikit-learn 5000. Regresja logistyczna używała solvera SAGA, natomiast SVM—`LinearSVC` z `dual=False`. Eksperyment uruchomiono jednym procesem dla zachowania jednoznacznego pomiaru czasu. Skrypt uruchomieniowy i zapis surowych predykcji znajdują się w commitach `1ed1525` (bazowy eksperyment) oraz `72345e1` (high-top5) gałęzi eksperymentalnej.

A.2 Dokładna dostępność splitów

Zapis a–b: m oznacza m dostępnych splitów dla każdego poziomu od a do b:

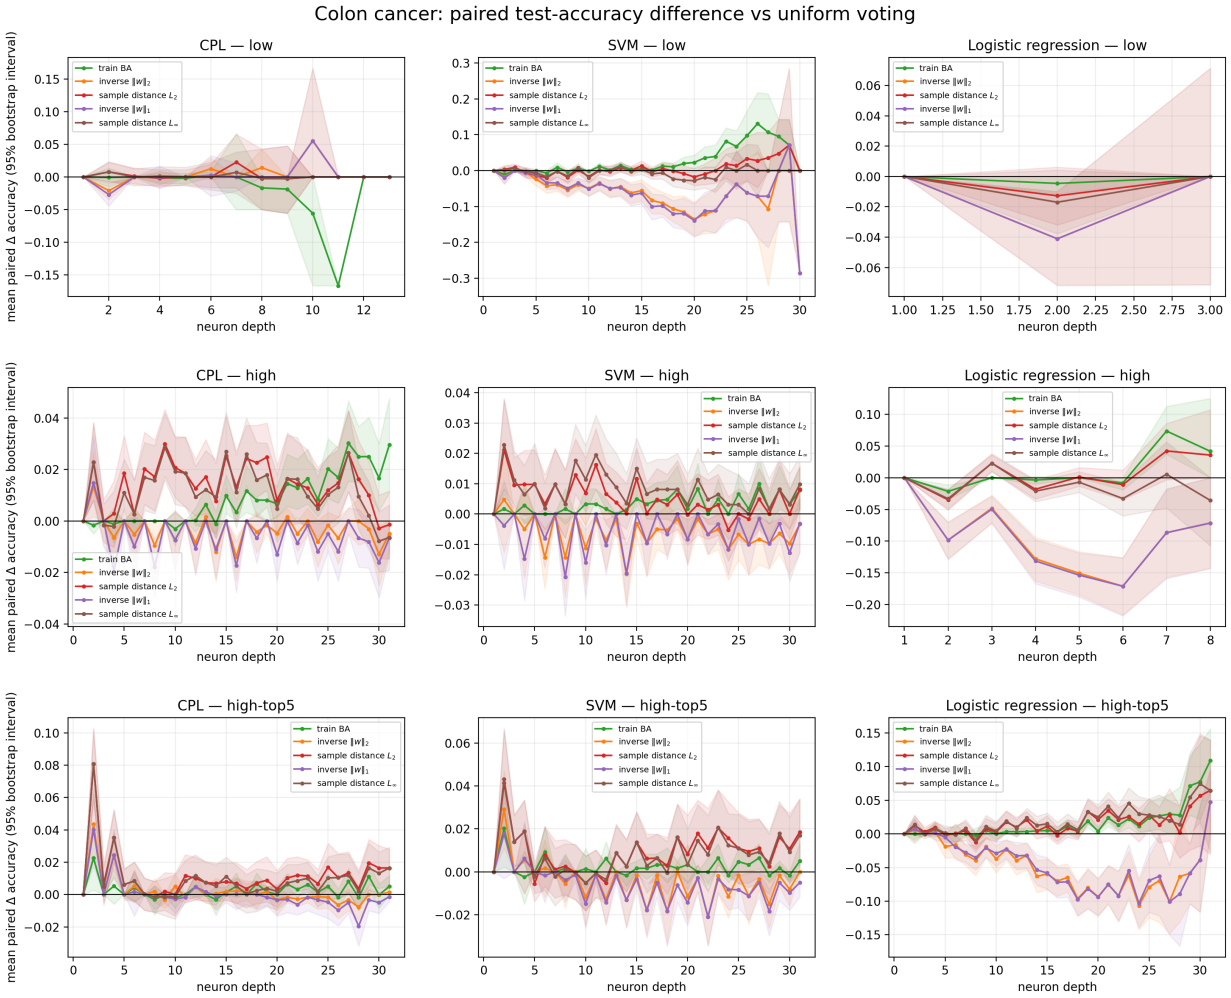
- CPL-low: 1–3: 100; 4: 99; 5: 80; 6: 51; 7: 20; 8: 10; 9: 9; 10: 3; 11–13: 1.
- SVM-low: 1–14: 100; 15: 99; 16: 96; 17: 86; 18: 74; 19: 65; 20: 50; 21: 38; 22: 26; 23: 18; 24: 12; 25: 10; 26: 6; 27: 4; 28: 3; 29: 2; 30: 1.
- Logistic regression-low: 1: 100; 2: 73; 3: 7.
- CPL-high: 1–31: 100.
- SVM-high: 1–31: 100.
- Logistic regression-high: 1–4: 100; 5: 98; 6: 61; 7: 22; 8: 4.
- CPL-high-top5: 1–31: 100.
- SVM-high-top5: 1–31: 100.
- Logistic regression-high-top5: 1–16: 100; 17–18: 99; 19: 93; 20: 85; 21: 74; 22: 62; 23: 50; 24: 44; 25: 35; 26: 25; 27: 17; 28: 12; 29: 11; 30: 8; 31: 7.

A.3 Reguła zatrzymania i przyczyny zakończenia

Po dopasowaniu neuronu wybierano współczynniki o wartości bezwzględnej większej niż 10^{-8} i odpowiadające im cechy usuwano z puli. Budowanie warstwy kończyło się, gdy (a) osiągnięto limit 31 neuronów, (b) nie pozostała żadna cecha albo (c) następny dopasowany model nie miał żadnego współczynnika przekraczającego próg. Model bez wybranej cechy nie był dołączany do warstwy.

Na podstawie liczby zbudowanych neuronów i zapisanych indeksów cech można odtworzyć przyczynę zakończenia. We wszystkich 100 splitach CPL-low, SVM-low, logistic regression-low i logistic regression-high zatrzymanie nastąpiło dlatego, że następny neuron nie wybrał żadnej cechy; pula wejściowa nie była jeszcze pusta. W CPL-high, SVM-high, CPL-high-top5 i SVM-high-top5 wszystkie 100 splitów osiągnęło narzucony limit 31 neuronów. Logreg-high-top5 osiągnął limit w 7 splitach, a pozostałe zatrzymały się wcześniej z powodu braku aktywnej cechy w następnym neuronie. Nie wystąpił przypadek całkowitego wyczerpania wszystkich 2000 cech przed osiągnięciem limitu.

A.4 Sparowane różnice accuracy

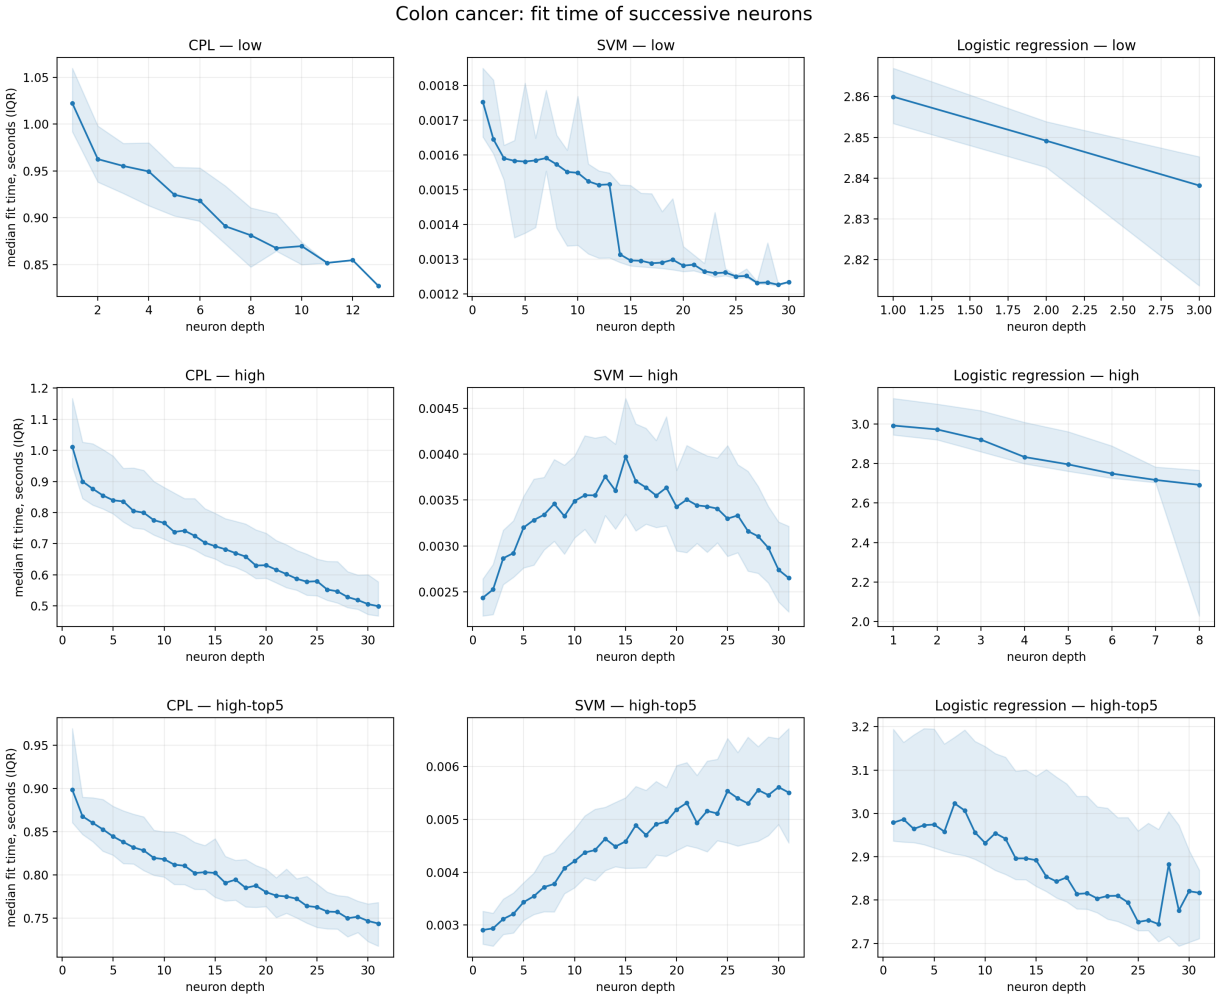


Rysunek 8: Średnia różnica test accuracy względem uniform voting, liczona parami na tym samym splicie i tej samej głębokości. Pas przedstawia opisowy 95% bootstrap percentile interval średniej z 5000 resamplowań. Linia zerowa oznacza brak różnicy.

Dla najlepszych wcześniej wskazanych głębokości sample-distance minus uniform wynosi średnio 0.0079 w CPL-low ($n = 2$) i 0.0186 w CPL-high ($n = 5$). Odpowiednie 95% przedziały bootstrapowe wynoszą $[-0.0069, 0.0233]$ oraz $[0.0055, 0.0324]$. W CPL-low metoda wygrała na 14 splitach, zremisowała na 77 i przegrała na 9; w CPL-high było to odpowiednio 13, 86 i 1.

Przedziały mają charakter opisowy. Splity powtarzanej walidacji krzyżowej nie są niezależnymi próbami, a głębokość została wybrana po obejrzeniu wyników. Nie są to więc przedziały potwierdzające istotność ostatecznie wybranej metody; do takiego wniosku potrzebny jest wybór strategii i głębokości w wewnętrznej CV.

A.5 Czas obliczeń



Rysunek 9: Mediana czasu trenowania kolejnych neuronów; pas przedstawia IQR pomiędzy dostępnymi splitami.

Konfiguracja	Czas całego runu [s]	Przybliżony czas
SVM low	20.1	20 s
SVM high	36.8	37 s
CPL low	654.3	10.9 min
CPL high	2286.6	38.1 min
Logreg low	528.7	8.8 min
Logreg high	1798.7	30.0 min
SVM high-top5	43.9	44 s
CPL high-top5	2549.6	42.5 min
Logreg high-top5	6977.1	116.3 min

Czas samego głosowania i obliczania metryk jest niewielki w porównaniu z dopasowaniem neuronów. Sześć strategii może być obliczanych po treningu z zapisanych score'ów, predykcji i norm współczynników.

A.6 Ograniczenie diagnostyki zbieżności

W starszych przebiegach low/high format wyników nie zapisywał `n_iter_` ani ostrzeżeń osobno dla neuronu i splitu, więc nie można retrospektywnie podać uczciwej liczby niezbieżnych dopasowań. W high-top5 diagnostyka została rozszerzona. Dla CPL i SVM wszystkie 3100 dopasowań selekcyjnych oraz 3100 refitów były oznaczone jako zbieżne. Dla logreg 2245 z 2321 szerokich dopasowań selekcyjnych osiągnęło limit iteracji; jednocześnie wszystkie 2176 wykonanych refitów top-5 zakończyły się bez `ConvergenceWarning`. Ostateczny neuron używany do predykcji jest modelem po reficie, lecz ranking pięciu cech pochodzi z często niezbieżnego modelu szerokiego. Dlatego wyniki logreg-high-top5 pozostają eksploracyjne i wymagają kontroli stabilności rankingu przy większym limicie iteracji lub innym solverze.